



**UNIVERSIDADE FEDERAL DO PARÁ
INSTITUTO DE CIÊNCIAS BIOLÓGICAS
FACULDADE DE BIOTECNOLOGIA**

Nome do Discente Estagiário: Polyana Silva de Araújo

Matrícula do Discente Estagiário: 202304840009

Tipo de estágio curricular: Interno (UFPA) com Supervisor externo da Faculdade

Nome completo do responsável da parte concedente: Prof. Dr. Adonney Allan de Oliveira Veras

E-mail do responsável da parte concedente do estágio: allanverasce@gmail.com



**UNIVERSIDADE FEDERAL DO PARÁ
INSTITUTO DE CIÊNCIAS BIOLÓGICAS
FACULDADE DE BIOTECNOLOGIA**

PLANO DE TRABALHO DE ATIVIDADES DE ESTÁGIO

**AValiação Comparativa de Pipeline de Anotação Genômica: Impacto na
Análise Pangenômica**

Resumo

A anotação genômica influencia diretamente a análise pangenômica, podendo introduzir vieses na definição de genes core, acessórios e singleton. Este estudo irá avaliar o impacto de diferentes pipelines de anotação na construção do pangenoma bacteriano. Genomas serão anotados com múltiplas ferramentas e comparados por métricas estatísticas e análises multivariadas. Espera-se identificar discrepâncias e propor diretrizes para maior robustez analítica.

1. Introdução

A era da genômica comparativa permitiu a transição do estudo de genomas isolados para a análise de populações bacterianas completas através do conceito de pangenoma. O pangenoma de uma espécie é definido como o conjunto total de genes encontrados em todos os seus isolados, sendo classicamente subdividido em: genoma core (genes presentes em todas ou quase todas as cepas, geralmente associados a funções biológicas essenciais), genoma acessório (presentes em algumas cepas, conferindo vantagens adaptativas específicas) e genes singletons ou exclusivos (Tettelin et al., 2005). Essa abordagem permitiu avanços significativos na compreensão de adaptação, virulência, resistência a antibióticos e evolução microbiana em diferentes contextos ecológicos e clínicos (Medini et al., 2005; Vernikos et al., 2015).

A construção de um pangenoma robusto depende intrinsecamente da qualidade da anotação genômica funcional e estrutural. A anotação é o processo de identificação de sequências codificantes (CDS), elementos não codificantes relevantes e a atribuição de funções biológicas a esses elementos, usualmente por métodos baseados em similaridade, perfis de homologia ou modelos probabilísticos. No entanto, a diversidade de algoritmos, parâmetros e bancos de dados utilizados por diferentes pipelines pode levar a discrepâncias significativas, tanto no número de genes previstos quanto na função atribuída a cada CDS (Richardson & Watson, 2013; Salzberg, 2019). Diferenças na detecção de ORFs curtos, na modelagem de códons de início e término, bem como na filtragem de pseudogenes, podem resultar em conjuntos anotados substancialmente distintos para o mesmo genoma.

Ferramentas amplamente difundidas como o Prokka (Seemann, 2014) utilizam bancos de dados de proteínas curados, mas podem apresentar limitações na identificação de novos genes ou na padronização de proteínas hipotéticas em comparação a ferramentas mais recentes e integradas a bancos de dados mais densos, como o Bakta (Schwengers et al., 2021), o PATRIC/RAPT (Wattam et al., 2017; Davis et al., 2020) e pipelines padronizados de centros de referência como o NCBI PGAP (Haft et al., 2018). Estudos comparativos mostram que o uso de diferentes anotadores em um mesmo conjunto de genomas bacterianos pode levar não apenas a variações no número total de CDS, mas também a divergências na anotação de vias metabólicas e fatores de

virulência, impactando diretamente interpretações funcionais e ecológicas (Norsigian et al., 2019; Zhang & Koblížek, 2017).

O problema torna-se ainda mais crítico no contexto pangenômico: pequenas variações na predição de sítios de início de tradução ou na sensibilidade de busca por homologia podem alterar drasticamente a classificação de um gene dentro do pangenoma (Manzano-Morales et al., 2023). Se um anotador falha em identificar um CDS em apenas uma de vinte cepas, um gene que deveria ser classificado como core pode ser erroneamente movido para a categoria de acessório. Inversamente, predições excessivamente permissivas podem inflar o número de genes singletons e artificialmente ampliar o pangenoma acessório (Vernikos et al., 2015; Earle et al., 2016). Além disso, a alta proporção de proteínas hipotéticas e anotações conflitantes dificulta a análise de inferências evolutivas, a identificação de marcadores diagnósticos precisos e a construção de modelos de associação genótipo-fenótipo robustos (Page et al., 2015; Tonkin-Hill et al., 2020).

Dada a crescente utilização de ferramentas como o Roary (Page et al., 2015), Panaroo (Tonkin-Hill et al., 2020), PIRATE (Bayliss et al., 2019) e outros métodos de clusterização de ortólogos para inferência pangenômica em larga escala, torna-se imperativo quantificar o quanto a escolha do software de anotação inicial influencia o resultado final do pangenoma. Trabalhos recentes têm sugerido que estratégias como correção de erros de anotação, filtragem de fragmentos gênicos e uso de grafos de variabilidade genética podem mitigar parcialmente esses vieses, mas não eliminam a dependência do conjunto de CDS de entrada (Li et al., 2020; Tonkin-Hill et al., 2020).

Este projeto justifica-se, portanto, pela necessidade de uma avaliação sistemática e comparativa de diferentes pipelines de anotação genômica no contexto da análise pangenômica bacteriana. Ao quantificar o impacto dessas escolhas na definição de genes core, acessórios e singletons, pretende-se estabelecer critérios claros para seleção e combinação de ferramentas bioinformáticas, bem como propor diretrizes metodológicas para padronização de estudos pangenômicos. Dessa forma, busca-se minimizar vieses computacionais e garantir que as conclusões biológicas reflitam a realidade genética da espécie em estudo, e não meras divergências algorítmicas ou de banco de dados.

2. Objetivo geral

Avaliar o impacto de diferentes softwares de anotação genômica na construção e caracterização do pangenoma de um conjunto de genomas bacterianos, quantificando as discrepâncias na proporção dos genes em core, acessório e singleton.

3. Objetivos específicos

- Comparar o número total de CDS preditos pelos anotadores Prokka, Bakta e PATRIC para um conjunto de genomas da mesma espécie.
- Quantificar a proporção de proteínas hipotéticas geradas por cada ferramenta e sua distribuição entre as categorias do pangenoma.
- Determinar o tamanho do pangenoma (core + acessório) e do core genome obtido com cada anotador, avaliando a concordância entre eles.
- Identificar genes classificados diferentemente entre os pipelines (ex.: core em um, acessório em outro) e analisar suas possíveis causas (e.g., falta de anotação funcional, diferenças nas extremidades dos genes).

4. Parte Experimental

A execução deste projeto será dividida em cinco etapas principais: seleção e preparo dos dados,

anotação genômica multi-pipeline, reconstrução pangenômica, análise estatística comparativa e automação do workflow.

4.1. Seleção e Preparo do Conjunto de Dados

A primeira etapa consiste na obtenção de genomas bacterianos de alta qualidade. Serão selecionados de 20 a 50 genomas completos de uma mesma espécie bacteriana (ex.: *Escherichia coli*, *Staphylococcus aureus*) disponíveis em bancos públicos (RefSeq/GenBank), levando em consideração apenas genomas classificados como “Complete Genome” ou “Chromosome”, para evitar que a fragmentação do assembly (contigs/scaffolds) interfira na predição de genes. Em seguida, as sequências serão padronizadas em formato FASTA.

4.2. Anotação

As sequências genômicas selecionadas serão submetidas a três fluxos de trabalho distintos. Cada ferramenta será executada utilizando parâmetros padrão para todos os genomas. Os softwares escolhidos devem incluir:

- Prokka (v1.14.6)
- Bakta (v1.7.0)
- PATRIC (via serviço online ou PATRIC Command Line Interface)

Para cada ferramenta, serão extraídos os arquivos de proteínas (.faa) e de coordenadas gênicas (.gff3).

4.3. Reconstrução e Análise Pangenômica

Para cada anotação, o pangenoma será construído de forma independente para cada anotador. Utilizaremos ferramentas de pangenômica (e.g., Roary, Panaroo, OrthoFinder) para gerar tabelas de presença/ausência de genes, adotando os mesmos parâmetros de clusterização, na qual a identidade mínima de sequência será fixada em 95% (limite padrão para espécies bacterianas) e parâmetros de cobertura em 80%.

4.4. Análise comparativa

Para quantificar e avaliar as discrepâncias entre os resultados das anotações, os dados serão processados no ambiente de programação Python (v.3.13). As seguintes métricas de comparação serão aplicadas:

- **Concordância de Conjuntos (Pangenomas):** O Índice de Jaccard (\$J\$) será utilizado para medir a similaridade entre os conjuntos de genes (pangenomas) gerados pelos diferentes anotadores.
- **Distribuição de Genes Codificadores (CDS):** Testes estatísticos (ANOVA de medidas repetidas ou teste de Wilcoxon, a ser definido após a verificação da normalidade dos dados) serão empregados para comparar a diferença no número total de Sequências Codificadoras (CDS) entre os resultados.
- **Contagem e Classificação Gênica:** Será realizada a contagem específica para os seguintes grupos de genes:
 - Genes Core (compartilhados por >95% dos genomas).
 - Genes Acessórios (compartilhados por um subconjunto).
 - Genes Singleton(exclusivos de um único genoma).

Um ponto focal da análise será a identificação e investigação de genes discrepantes, ou seja, genes classificados como core por um anotador e com outra classificação por outro. Será investigado se esses genes são hipotéticos ou se possuem funções específicas relevantes. Para visualização e identificação de agrupamentos de genomas com base no anotador, serão aplicadas técnicas de redução de dimensionalidade, Análise de Componentes Principais (PCA) ou Escalonamento Multidimensional (MDS), às matrizes de presença/ausência de genes. Adicionalmente, serão realizados testes de permutação para validar se as diferenças observadas entre os resultados dos anotadores são estatisticamente significantes e maiores do que o esperado por acaso.

5. Cronograma de execução

ATIVIDADES	2026 (SEMANAS)								
	1-2	3-4	5-6	7-8	9-10	11-12	13-14	15-16	17
Revisão Bibliográfica	X	X							
Seleção dos genomas		X							
Anotações			X	X					
Análise Pangenômica					X				
Análises estatísticas						X			
Construção de gráficos e tabelas						X			
Relatório Final							X		
Apresentação Oral								X	Envio de documentos

6. Referências

- BAYLISS, S. C. et al. PIRATE: A fast and scalable pangenomics toolbox for clustering diverged orthologues in bacteria. *GigaScience*, v. 8, n. 10, giz119, 2019.
- DAVIS, J. J. et al. The PATRIC Bioinformatics Resource Center: expanding data and analysis capabilities. *Nucleic Acids Research*, v. 48, n. D1, p. D606–D612, 2020.
- EARLE, S. G. et al. Identifying lineage effects when controlling for population structure improves power in bacterial association studies. *Nature Microbiology*, v. 1, 16041, 2016.
- HAFT, D. H. et al. RefSeq: an update on prokaryotic genome annotation and curation. *Nucleic Acids Research*, v. 46, n. D1, p. D851–D860, 2018.

- LI, H. et al. Graph-based pangenomics methods and applications. *Current Opinion in Genetics & Development*, v. 62, p. 48–55, 2020.
- LI, W. et al. Panaroo: accurate and reproducible pan-genome analysis with distributed computing. **Bioinformatics**, [s. l.], 2021.
- MANZANO-MORALES, M. A. et al. Systematic evaluation of annotation errors in bacterial genomes and their impact on comparative genomics. *BMC Genomics*, v. 24, 123, 2023.
- MEDINI, D. et al. The microbial pan-genome. *Current Opinion in Genetics & Development*, v. 15, n. 6, p. 589–594, 2005.
- NORSIGIAN, C. J. et al. Constraint-based modeling of metabolism in prokaryotes: the expanded annotation challenge. *Biochimica et Biophysica Acta – General Subjects*, v. 1863, n. 6, p. 1294–1305, 2019.
- PAGE, A. J. et al. Roary: rapid large-scale prokaryote pan genome analysis. *Bioinformatics*, v. 31, n. 22, p. 3691–3693, 2015.
- RICHARDSON, E. J.; WATSON, M. The automatic annotation of bacterial genomes. *Briefings in Bioinformatics*, v. 14, n. 1, p. 1–12, 2013.
- SALZBERG, S. L. Next-generation genome annotation: we still struggle to get it right. *Genome Biology*, v. 20, 92, 2019.
- SCHWENGERS, O. et al. Bakta: rapid and standardized annotation of bacterial genomes via alignment-free sequence identification. *Microbial Genomics*, v. 7, n. 11, 000685, 2021.
- SEEMANN, T. Prokka: rapid prokaryotic genome annotation. *Bioinformatics*, v. 30, n. 14, p. 2068–2069, 2014.
- TANIZAWA, Y. et al. DFAST: a flexible prokaryotic genome annotation pipeline for faster genome publication. **Bioinformatics**, [s. l.], 2018.
- TATUSOVA, T. et al. NCBI Prokaryotic Genome Annotation Pipeline. **Nucleic Acids Research**, [s. l.], 2016.
- TETTELIN, H. et al. Genome analysis of multiple pathogenic isolates of *Streptococcus agalactiae*: implications for the microbial “pan-genome”. *Proceedings of the National Academy of Sciences of the USA*, v. 102, n. 39, p. 13950–13955, 2005.
- TONKIN-HILL, G. et al. Producing polished prokaryotic pangenomes with the Panaroo pipeline. *Genome Biology*, v. 21, 180, 2020.
- VERNIKOS, G.; MEDINI, D.; RILEY, D. R.; TETTELIN, H. Ten years of pan-genome analyses. In: TETTELIN, H.; MEDINI, D. (org.). *The Pangenome: Diversity, Dynamics and Evolution of Genomes*. Cham: Springer, 2015. p. 1–20.
- WATTAM, A. R. et al. PATRIC, the bacterial bioinformatics database and analysis resource. **Nucleic Acids Research**, [s. l.], 2017.
- WATTAM, A. R. et al. Improvements to PATRIC, the all-bacterial Bioinformatics Database and Analysis Resource Center. *Nucleic Acids Research*, v. 45, n. D1, p. D535–D542, 2017.
- ZHANG, J.; KOBLÍŽEK, M. Genome annotation errors in microbial photoheterotrophs: the case of aerobic anoxygenic phototrophs. *Frontiers in Microbiology*, v. 8, 1759, 2017.